

# HW6 新創公司獲利預測分析與特徵選擇

## Kaggle 50 Startups Profit Prediction & CRISP-DM 實作講義

本講義為機器學習實務課程專作。本專案使用 Kaggle 的 50 Startups 資料集，完整落實了 CRISP-DM (Cross-Industry Standard Process for Data Mining) 的六大階段。包含商業理解、資料清洗、類別特徵編碼 (加州虛擬變數 Baseline 防範陷阱)、模型擬合、5種特徵選擇方法之交叉比對，最後儲存最佳二特徵迴歸模型並部署互動式 Streamlit 網頁應用。




圖 1：完整特徵 (包含 OHE 州別) 之皮爾森相關係數熱力圖

## 第一節：模型建置與特徵子集表現對比

我們採用多元線性迴歸作為核心預估模型，並在測試集上 ( `test_size=0.2`, `random_state=42` ) 比較了 5 組不同數量的特徵子集表現。如下表所示，隨著特徵數增加，指標呈現非線性變化：

| 模型名稱                                            | 包含特徵數 | RMSE    | MAE     | R-squared | Adjusted R2 |
|-------------------------------------------------|-------|---------|---------|-----------|-------------|
| 1 Feature (R&D;)                                | 1     | 7714.33 | 6077.36 | 0.9265    | 0.9173      |
| 2 Features (R&D; + Marketing)                   | 2     | 8206.33 | 6469.18 | 0.9168    | 0.8931      |
| 3 Features (R&D; + Marketing + NY)              | 3     | 8242.78 | 6430.58 | 0.9161    | 0.8741      |
| 4 Features (R&D; + Marketing + NY + FL)         | 4     | 8254.69 | 6454.51 | 0.9159    | 0.8485      |
| 5 Features (R&D; + Marketing + NY + FL + Admin) | 5     | 9055.96 | 6961.48 | 0.8987    | 0.7721      |




圖 2：測試集上 RMSE 隨特徵數量增加的變化趨勢圖

## 第二節：5 種特徵篩選方法交叉分析

為客觀驗證哪些特徵對 Profit 貢獻最高，本專案實作了五種主流的特徵篩選演算法，包括：其一是 SFS (Forward)、其二是 RFE、其三是 SelectKBest、其四是 Lasso L1 迴歸、以及其五是隨機森林重要性。排名彙整如下：

| 特徵名稱            | SFS Forward | RFE | SelectKBest | Lasso | Random Forest | 平均排名 |
|-----------------|-------------|-----|-------------|-------|---------------|------|
| R&D; Spend      | 1           | 3   | 1           | 1     | 1             | 1.4  |
| Marketing Spend | 2           | 5   | 2           | 2     | 2             | 2.6  |
| Florida         | 4           | 2   | 4           | 4     | 4             | 3.6  |
| Administration  | 3           | 4   | 5           | 3     | 3             | 3.6  |
| New York        | 5           | 1   | 3           | 5     | 5             | 3.8  |




圖 3：5 種特徵篩選方法之特徵重要性排名對比熱力圖

### 第三節：最佳模型方程式與殘差診斷

綜合多模型指標對比與特徵重要度分析，雖然單特徵模型的 RMSE 表現略優（屬測試集小樣本之抖動），但考量到業務操作的完整度，我們採用 2 Features (R&D; Spend + Marketing Spend) 作為最終模型的特徵組合：

$$\text{Profit} = 50286.8118 + 0.8056 * (\text{R\&D; Spend}) + 0.0272 * (\text{Marketing Spend})$$

係數解讀：在其他條件不變的情況下，公司每投入 1 美元於研發（R&D; Spend），獲利預估邊際增加 0.81 美元；而投入於行銷（Marketing Spend），預期僅能邊際回收 0.03 美元利潤。這說明研發對該新創數據集具有絕對優勢的驅動力。




圖 4：最佳模型的擬合散佈圖 (上) 與殘差分佈圖 (下)

## 附錄：CRISP-DM 實作手繪風知識圖卡 (Infographic)

以下為利用 Excalidraw 手繪 chalk 風格繪製的直式 A4 知識圖卡，彙整了 Business 理解、資料前處理陷阱避防、多元模型比對與特徵選擇的核心推論。




圖 5：Kaggle 50 Startups Profit Prediction CRISP-DM 流程手繪風知識圖卡